

คู่มือการติดตั้งและการใช้งานโปรแกรมในคลัง GitHub

iBond_LIME, leadning_time และ ibond_EWS: โครงสร้างโปรแกรม วิธีติดตั้ง วิธีรัน และผลการรันบน Dataset2

สารบัญ

1. วัตถุประสงค์และขอบเขต	3
2. ข้อมูล Dataset2	4
3. การติดตั้ง	5
3.1 สิ่งที่ต้องมี	5
3.2 ดาวน์โหลดคลัง	6
3.3 ติดตั้งแพ็คเกจ	6
3.4 ตั้งค่านำจอให้แสดงภาษาไทย	6
4. คลังที่หนึ่ง iBond_LIME: อธิบายผลด้วย LIME และ SHAP	6
4.1 หน้าทีของคลัง	6
4.2 โครงสร้างโปรแกรม	7
4.3 ผังการทำงานของโปรแกรมหลัก	8
4.4 วิธีรันทีละคำสั่ง	8
4.5 ผลการรันบน Dataset2	10
5. คลังที่สอง leadning_time: วัด lead time	15
5.1 หน้าทีของคลัง	15
5.2 โครงสร้างโปรแกรม	15
5.3 วิธีรัน dynamic_lead_time.py	15
5.4 วิธีรัน dataset2_leadtime_standalone.py	16
5.5 ผลการรันบน Dataset2	17
6. คลังที่สาม ibond_EWS: ระบบเตือนภัยและหน้าจอโปรแกรม	20
6.1 หน้าทีของคลัง	20
6.2 โครงสร้างโปรแกรม	21

6.3 การติดตั้งและสร้างฐานข้อมูล	21
6.4 วิธีรัน	22
6.5 ผลการรันบน Dataset2	23
7. สิ่งปรับปรุงในคลัสรอบนี้และข้อควรทราบ	25
7.1 iBond_LIME	25
7.2 leading_time	26
7.3 ibond_EWS	26
7.4 ข้อควรทราบ	26
ภาคผนวก ก. คำสั่งทั้งหมดโดยย่อ	27

1. วัตถุประสงค์และขอบเขต

เอกสารนี้เป็นคู่มือการติดตั้งและการรัน โปรแกรมในคลัง GitHub สามแห่งของระบบเตือนภัยล่วงหน้าสำหรับหุ้นกู้ภาคเอกชน อธิบายโครงสร้าง โปรแกรม วิธีติดตั้ง และวิธีรันทีละคำสั่ง แล้วรายงานผลที่ได้จากการรันจริงบนชุดข้อมูล Dataset2 ทั้งสามคลัง ตาราง 1 สรุปหน้าที่ของแต่ละคลัง

Table 1: คลังโปรแกรมทั้งสามแห่ง

คลัง	ที่อยู่	หน้าที่
iBond_LIME	https://github.com/kkabinsky/iBond_LIME	อธิบายว่าทำไม บริษัท หนึ่งมีค่า PD สูงหรือต่ำ ด้วย LIME และ SHAP พร้อมคิวตรวจแบบ rolling window และ segmented model
leadning_time	https://github.com/kkabinsky/leadning_time	วัดว่าระบบเตือน ก่อนเหตุการณ์จริง ได้กี่เดือน (lead time) และจับบริษัทที่เกิดเหตุการณ์ได้กี่ราย
ibond_EWS	https://github.com/kkabinsky/ibond_EWS	ระบบเตือนภัยเต็มรูปแบบ มีหน้าจอ โปรแกรม ค่า PD เส้นเตือนภัย การ shock รายบริษัท และระบบ Dataset2 ในโพลเดอร์ dataset2/

ผลในเอกสารนี้มาจากการรันจริงทุกตัวเลข ทุกคำสั่งในเอกสารนี้รันบน Dataset2 เมื่อวันที่ 26 กันยายน 2026 บนสำเนาที่ clone ใหม่จากคลัง ไม่ได้รันในโพลเดอร์ทำงานเดิม เพื่อยืนยันว่าผู้ใช้ที่ได้คลังไปใหม่รันตามคู่มือนี้ได้จริง เครื่องที่ใช้ทดสอบคือ Windows 11 กับ Python 3.14.4 เวลาที่ทำงานเป็นเวลาโดยประมาณบนเครื่องนี้ ขณะที่ทีมงานอื่นรันอยู่ด้วย

สามคลังทำงานต่อกันอย่างไร รูปที่ 1 แสดงว่าทั้งสามคลังอ่านข้อมูลชุดเดียวกัน แต่ตอบคนละคำถาม ibond_EWS ให้ค่า PD และเส้นเตือนภัย leadning_time วัดว่าเส้นเตือนภัยนั้นเตือนได้ทันเวลาหรือไม่ และ iBond_LIME อธิบายว่าตัวแปรใดทำให้บริษัทนั้นถูกเตือน




Figure 1: ความสัมพันธ์ของคลังทั้งสามแห่งกับข้อมูล Dataset2

ลำดับของเอกสาร หัวข้อที่ 2 อธิบายข้อมูล หัวข้อที่ 3 อธิบายการติดตั้งที่ใช้ร่วมกันทั้งสามคลัง หัวข้อที่ 4 ถึง 6 เป็นคู่มือของแต่ละคลัง เรียงจากโครงสร้างโปรแกรม วิธีรัน ไปจนถึงผลที่ได้ หัวข้อที่ 7 สรุปสิ่งที่ปรับปรุงในคลังรอบนี้และข้อควรทราบ ส่วนภาคผนวก ก รวมคำสั่งทั้งหมดไว้ในหน้าเดียว

2. ข้อมูล Dataset2

ทั้งสามคลังใช้ตาราง `ibond_33features_panel_941firm` เป็นข้อมูลหลัก ตาราง 2 สรุปตัวเลขสำคัญ ทุกตัวเลขนับจากตารางจริงด้วยคำสั่ง `inspect` ของโปรแกรมคำนวณ `lead time`

Table 2: ตัวเลขหลักของ Dataset2

รายการ	ค่า
ชื่อตาราง	<code>ibond_33features_panel_941firm</code>
บริษัท-เดือน	187,007 แถว 95 คอลัมน์
บริษัท	941 ราย ทั้งตลาด SET และ mai
ช่วงเวลา	1984-01 ถึง 2026-08
ตัวแปรที่เข้าแบบจำลอง	30 ตัว (ตาราง 3)
ตัวแปรตาม	<code>y_pre3m</code> เท่ากับ 1 เมื่อบริษัทตัดสินใจชำระหนี้หรือปรับโครงสร้างหนี้จริงภายในเดือนนี้ถึงสามเดือนข้างหน้า
เดือนที่ <code>y_pre3m = 1</code>	124 เดือน จาก 31 บริษัท คิดเป็นร้อยละ 0.066
บริษัทที่เกิดเหตุการณ์	32 ราย โดย 31 รายมีเดือนเริ่มเหตุการณ์ชัดเจน อีก 1 รายทราบจากคอลัมน์สถานะเท่านั้น

Table 3: ตัวแปร 30 ตัวที่เข้าแบบจำลอง แบ่งเป็นห้ากลุ่ม

กลุ่ม	ตัวแปร
สภาพคล่องการซื้อขาย (5)	<code>amihud_monthly</code> , <code>adj_illiq_kz</code> , <code>percent_zero_days</code> , <code>zero_days</code> , <code>n_days</code>
อัตราส่วนทางการเงิน (14)	<code>ROA</code> , <code>ROE</code> , <code>DE</code> , <code>CurrentRatio</code> , <code>QuickRatio</code> , <code>CashRatio</code> , <code>EBITtoTA</code> , <code>REtoTA</code> , <code>WorkingCapitaltoTA</code> , <code>TDTA</code> , <code>LTDtoTA</code> , <code>STDtoTA</code> , <code>cf_Interestcoverageratio</code> , <code>acc_DebtServiceCoverageRatio</code>
ขนาดและอายุ (2)	<code>lnTotalAssets</code> , <code>lnAge</code>
เศรษฐกิจมหภาค (3)	<code>Policyrate</code> , <code>GDPgrowth</code> , <code>UnemploymentratemodeledILOe</code>
ธรรมาภิบาลและ ESG (6)	<code>ESGScore</code> , <code>GovernancePillarScore</code> , <code>EnvironmentalPillarScore</code> , <code>SocialPillarScore</code> , <code>IndependentBoardMembers</code> , <code>AverageBoardTenure</code>

ข้อมูลอยู่ที่ไหนในแต่ละคลัง ทั้งสามคลังแบบ Dataset2 มาในตัว ผู้ใช้จึงไม่ต้องหาฐานข้อมูลเอง ตาราง 4 บอกว่าแต่ละคลังเก็บไว้ในรูปใด และโปรแกรมเปิดใช้อย่างไร

Table 4: ตำแหน่งของ Dataset2 ในแต่ละคลัง

คลัง	ไฟล์ที่แนบมา	โปรแกรมเปิดใช้อย่างไร
iBond_LIME	lime_credit.db.zip (23.9 MB)	คลายซิปเองเป็น lime_credit.db (121 MB) ในการรันครั้งแรก
leadning_time	lime_credit.db.zip (ไฟล์เดียวกัน)	คลายซิปเองในการรันครั้งแรกเช่นกัน
ibond_EWS	dataset/ibond_33features_panel_941firm.csv.gz (17.3 MB)	สั่ง python dataset/build_db.py ครั้งเดียวได้ cmdf_credit.db (109.5 MB) ที่รากของคลัง

ตรวจสอบแล้วว่าข้อมูลทั้งสามแห่งเป็นชุดเดียวกัน ตาราง Dataset2 ในฐานข้อมูลทำงานเดิม cmdf_credit.db กับใน lime_credit.db ให้ค่า hash เดียวกันเมื่อคำนวณจากทั้ง 95 คอลัมน์ ส่วนฐานข้อมูลที่ ibond_EWS สร้างกลับจากไฟล์ CSV ให้ตัวแปรเข้าแบบจำลองตรงกันทุกค่า ผลต่างสูงสุดเป็นศูนย์ ตัวแปรตามตรงกันทุกแถว และบัญชีเหตุการณ์ 31 และ 32 รายตรงกัน ดังนั้นตัวเลขที่ได้จากคลังใดก็ตาม เทียบกันได้โดยตรง

3. การติดตั้ง

3.1 สิ่งที่ต้องมี

- Python 3.10 ขึ้นไป เครื่องทดสอบใช้ 3.14.4
- git สำหรับ clone คลัง หรือดาวน์โหลดเป็นไฟล์ zip จากหน้า GitHub ก็ได้
- พื้นที่ว่างราว 1 GB สำหรับฐานข้อมูลที่คลายแล้วและผลการรัน
- XeLaTeX และฟอนต์ Angsana New เฉพาะกรณีต้องการคอมไพล์คู่มือนี้ใหม่

ตาราง 5 คือรุ่นของแพ็คเกจบนเครื่องที่ใช้ทดสอบ รุ่นที่ใหม่กว่านี้ควรใช้ได้ แต่ถ้าต้องการผลตรงกับเอกสารนี้ทุกตัวเลข ควรใช้รุ่นเดียวกัน

Table 5: รุ่นของแพ็คเกจที่ใช้ทดสอบ

แพ็คเกจ	รุ่น	แพ็คเกจ	รุ่น
numpy	2.4.4	catboost	1.2.10
pandas	3.0.2	lightgbm	4.6.0
scikit-learn	1.8.0	lime	0.2.0.1
scipy	1.17.1	shap	0.52.0
xgboost	3.2.0	statsmodels	0.14.6
matplotlib	3.10.8	flet	0.84.0
openpyxl	3.1.5	xlsxwriter	3.2.9
Pillow	12.2.0		

3.2 ดาวน์โหลดคลัง

วางทั้งสามคลังไว้ในโฟลเดอร์เดียวกัน เช่น D:\work แต่ละคลังทำงานแยกกันได้ ไม่ต้องอยู่ติดกัน

```
cd D:\work
git clone https://github.com/kkabinsky/iBond_LIME.git
git clone https://github.com/kkabinsky/leadning_time.git
git clone https://github.com/kkabinsky/ibond_EWS.git
```

3.3 ติดตั้งแพ็คเกจ

แนะนำให้สร้าง virtual environment ก่อน แล้วติดตั้งตามไฟล์ requirements ของแต่ละคลัง

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install -r iBond_LIME\requirements.txt
python -m pip install -r leadning_time\requirements-standalone.txt
python -m pip install -r ibond_EWS\requirements.txt
```

ไฟล์ requirements-standalone.txt ของ leadning_time ครอบคลุมทั้งสองโปรแกรมในคลังนั้น ถ้าจะใช้เฉพาะ dynamic_lead_time.py ติดตั้งแค่ requirements-catboost.txt ก็พอ ส่วน ibond_EWS มีแพ็คเกจเสริม เช่น torch และ yfinance ที่ใช้เฉพาะบางโปรแกรม ถ้าไม่ใช้ส่วนนั้นลบบรรทัดออกได้

3.4 ตั้งค่าหน้าจอให้แสดงภาษาไทย

หลายโปรแกรมพิมพ์ผลเป็นภาษาไทย บน Windows ที่หน้าจอยังเป็น code page 874 อาจเกิด UnicodeEncodeError ให้ตั้งค่านี้ก่อนรันทุกครั้งใน PowerShell

```
$env:PYTHONIOENCODING = "utf-8"
```

ถ้าใช้ Git Bash ใช้ export PYTHONIOENCODING=utf-8 แทน

4. คลังที่หนึ่ง iBond_LIME: อธิบายผลด้วย LIME และ SHAP

4.1 หน้าทีของคลัง

แบบจำลองให้ค่า $\widehat{PD}_{3M}$ ของแต่ละบริษัท แต่ไม่ได้บอกว่าทำไม คลังนี้ตอบคำถามนั้นด้วยสองวิธีที่อธิบายค่าเดียวกัน คือ LIME ซึ่งสุ่มจุ่มรอบบริษัทแล้วพีดเส้นตรงเฉพาะที่ และ SHAP ซึ่งแยกค่าที่ทำนายออกเป็นส่วนของแต่ละตัวแปร นอกจากนี้ยังจัดคิวบริษัทที่ควรตรวจด้วยเส้นเดือนถัดมาตามกำลังคน 5% แบบรวมทั้งตลาดหรือแยกกลุ่ม SET กับ mai และแบบดูย้อนหลัง 12 หรือ 24 เดือน

4.2 โครงสร้างโปรแกรม

Table 6: ไฟล์ในคลัง iBond_LIME

ไฟล์	หน้าที่	ข้อมูล
lime33_adapter_panel.py	โปรแกรมหลัก คิวตรวจแบบ segmented และ rolling window พร้อมรูปสามช่องและ Excel	1, 2
data_adapter.py	เลือกชุดข้อมูล 1 หรือ 2 เปิดฐานข้อมูล และคลาซิปให้เอง	1, 2
lime_feature33.py	LIME กับ SHAP เทียบกันรายบริษัท SHAP อยู่ในหน่วยเดียวกับ PD	1, 2
batch_run_20_issuers.py	สร้างรูปอธิบายผลของบริษัทที่ PD สูงสุด N ราย	1, 2
benchmark_rolling_segmented.py	เปรียบเทียบกลยุทธ์เตือนภัยหกแบบ	2
evaluate_methods_abc.py	ประเมินวิธี A, B, C บนทั้งสองชุดข้อมูล	1, 2
dataset2_leadtime_standalone.py	ขั้นที่ 1 ของ LIME หลาย โมเดล: ฝึก 5 หรือ 9 โมเดลแล้ววัด lead time	2
dataset2_multimodel_lime.py	ขั้นที่ 2: LIME ของ 5 โมเดล ณ เดือนที่แต่ละโมเดลเตือนจริง	2
a_approach.py	คิวตรวจสามชั้น ระดับ PD ความแปรปรวน และงบแก้ไขที่ถูกรับ	1
firm_shock_panel.py	การ shock ตัวแปรรายบริษัท ใช้โดย a_approach.py	1
cmdf_tree_classify.py	อ่านแฟงข้อมูลชุดที่ 1 ให้ firm_shock_panel.py	1
lime_credit.db.zip	ฐานข้อมูลบีบอัด มีทั้งชุดที่ 1 และชุดที่ 2	–
lime33.tex, lime33.pdf	คู่มือฉบับเต็มเดิม 50 หน้า	–
output/, tex_out/	ผลรูป JPG/PNG ตาราง CSV และ Excel	–

ช่องข้อมูล 1 คือชุดข้อมูลเดิม ibond_33features_panel (16,986 แถว 293 ผู้ออก) และ 2 คือ Dataset2

4.3 ฟังก์ชันการทำงานของโปรแกรมหลัก




Figure 2: ฟังก์ชันการทำงานของ lime33_adapter_panel.py

4.4 วิธีรันทีละคำสั่ง

ทุกคำสั่งรันจากโฟลเดอร์ iBond_LIME การรันครั้งแรกจะคลายซิปฐานข้อมูลก่อน ใช้เวลาเพิ่มราว 5 วินาที

ก. โปรแกรมหลัก lime33_adapter_panel.py

```
python lime33_adapter_panel.py
python lime33_adapter_panel.py -d 2 --segmented -w 12 --issuer ITD
python lime33_adapter_panel.py -d 2 --segmented -w 12 --all-high-risk
python lime33_adapter_panel.py -d 2 -w 24 --issuer EA
```

Table 7: ตัวเลือกของ lime33_adapter_panel.py

ตัวเลือก	ค่าเริ่มต้น	ความหมาย
-d, --dataset	เมนู	1 = ชุดเดิม, 2 = Dataset2 ถ้าไม่ระบุจะแสดงเมนูให้เลือก กด Enter ได้ชุดที่ 2
--issuer	-	รหัสบริษัทที่ต้องการอธิบาย เช่น PTT, ITD, EA
--all-high-risk	-	อธิบายทุกบริษัทในความเสี่ยงสูง และรวมเป็น Excel ไฟล์เดียว
-s, --segmented	ปิด	แยกเส้นเดือนกับของกลุ่ม SET กับกลุ่ม mai
-w, --rolling-window	12	จำนวนเดือนย้อนหลังที่ใช้ตัดสินใจอยู่ในคว ใส 1 เพื่อดูเดือนล่าสุดเดือนเดียว

ถ้าไม่ระบุทั้ง --issuer และ --all-high-risk โปรแกรมจะถามรหัสบริษัทที่ละราย กด Enter ว่างเพื่อจบ ผลของแต่ละบริษัทเขียนลงสามที่ คือ output/lime_jpg/, output/lime_figs/ และ output/excel/ ส่วนไฟล์รวมอยู่ที่ output/xai_credit_risk_master_report.xlsx

ข. LIME กับ SHAP เทียบกัน lime_feature33.py

```
python lime_feature33.py -d 2 --issuer PTT
python lime_feature33.py -d 2 --issuer TPOLY --repeats 15 --samples 8000
python lime_feature33.py -d 2 --all-high-risk
python lime_feature33.py -d 2 --issuer SST --top 12 --no-figure
```

Table 8: ตัวเลือกของ lime_feature33.py

ตัวเลือก	ค่าเริ่มต้น	ความหมาย
-d, --dataset-choice	เมนู	1 หรือ 2 ถ้าไม่ระบุและรันแบบมีหน้าจอจะแสดงเมนู ถ้ารันแบบไม่มีหน้าจอ เช่นจาก scheduler จะใช้ชุดที่ 2
--issuer	PD สูงสุด	บริษัทที่ต้องการ ถ้าไม่ระบุจะเลือกบริษัทที่ PD สูงสุดที่อยู่เหนือเส้น
--all-high-risk	-	ทำทุกบริษัทที่อยู่เหนือเส้นเดือนกับ
--samples	5,000	จำนวนจุดสุ่มของ LIME ต่อหนึ่ง seed
--repeats	8	จำนวน seed ที่รันซ้ำ
--top	10	จำนวนตัวแปรที่แสดง
--workload	0.05	กำลังคนที่ใช้ตั้งเส้นเดือนกับ
--no-figure	-	ไม่สร้างไฟล์รูป

ค. รูปของบริษัทที่ PD สูงสุด N ราย

```
python batch_run_20_issuers.py
python batch_run_20_issuers.py -d 2 --n 5 --samples 2500 --repeats 6
```

ได้รูปใน tex_out/lime_jpg/ กับ tex_out/lime_figs/ และตาราง tex_out/generated_20_issuers.csv (เลข 20 เปลี่ยนตามค่า --n)

ง. เปรียบเทียบกลยุทธ์เตือนภัยและวิธี A, B, C

```
python benchmark_rolling_segmented.py
python evaluate_methods_abc.py
```

โปรแกรมแรกเขียนผลลง tex_out/comparison_rolling_segmented.csv โปรแกรมที่สองพิมพ์ผลทั้งชุดที่ 1 และชุดที่ 2

จ. LIME ของห้าโมเดล ณ เดือนที่เตือนจริง (สองขั้น)

ขั้นที่ 1 ฝึกห้าโมเดลด้วยการแบ่ง fold ตามบริษัท แล้ววัด lead time ขั้นที่ 2 อ่านผลขั้นที่ 1 ล่าสุดเอง สร้างโมเดลของแต่ละ fold ขึ้นใหม่ ตรวจสอบว่าได้ค่า PD ตรงกับขั้นที่ 1 แล้วจึงรัน LIME ณ เดือนที่โมเดลนั้นเตือนก่อนเหตุการณ์ LIME ไม่ได้สร้างการเตือนเอง ใช้อธิบายการเตือนที่เกิดขึ้นแล้วเท่านั้น

```
python dataset2_leadtime_standalone.py run --models xgboost catboost random_forest logistic lightgbm
python dataset2_multimodel_lime.py run
python dataset2_multimodel_lime.py run --seeds 17 29 43 61 83 --samples 750
```

ขั้นที่ 2 รับเฉพาะผลขั้นที่ 1 ที่มีห้าโมเดลนี้ตามลำดับนี้พอดี ถ้าขั้นที่ 1 รันครบเก้าโมเดลซึ่งเป็นค่าเริ่มต้น ขั้นที่ 2 จะไม่หยิบผลนั้นไปใช้ผลขั้นที่ 1 อยู่ใน standalone_leadtime_runs/ ผลขั้นที่ 2 อยู่ใน standalone_lime_runs/ ตั้งชื่อไฟล์เคอร์ตามวันเวลาที่รัน จึงไม่ทับผลเดิม

ฉ. ชุดข้อมูลเดิม (ชุดที่ 1)

```
python lime33_adapter_panel.py -d 1 --issuer A
python a_approach.py
python a_approach.py --explain SQ
```

a_approach.py และ firm_shock_panel.py อ่านตาราง ibond_33features_panel ซึ่งเป็นชุดที่ 1 โดยตรง จึงใช้กับ Dataset2 ไม่ได้ ส่วน cmdf_tree_classify.py ในคลังนี้ทำหน้าที่อ่านข้อมูลให้โปรแกรมอื่น ไม่ได้ออกแบบให้รันเดี่ยว

4.5 ผลการรันบน Dataset2

คำสั่งที่รันและเวลาที่ใช้ ตาราง 9 คือคำสั่งที่รันจริงบนสำเนาใหม่ของคลัง ทุกคำสั่งจบโดยไม่มีข้อผิดพลาด

Table 9: คำสั่งที่รันในคลัง iBond_LIME และผลโดยย่อ

คำสั่ง	วินาที	ผลโดยย่อ
lime33_adapter_panel.py -d 2 --issuer PTT	24	รวมเวลาคล้ายชิป คิวเสี่ยงสูง 243 ราย
lime33_adapter_panel.py -d 2 --segmented -w 12 --issuer ITD	61	PD 0.011311 ต่ำกว่าเส้น 0.080360
lime_feature33.py -d 2 --issuer PTT	33	เส้น 0.127681 เหนือเส้น 48 ราย
batch_run_20_issuers.py --n 3	49	LRH, GLAND, CV
benchmark_rolling_segmented.py	63	ตรงกับตารางใน README ทุกช่อง
evaluate_methods_abc.py	78	ชุดที่ 1 จับได้ 8/8, ชุดที่ 2 จับได้ 15/31
dataset2_leadtime_standalone.py run(5 โมเดล)	115	ตาราง 11
dataset2_multimodel_lime.py run	144	ตาราง 12
lime33_adapter_panel.py -d 1 --issuer A	10	ชุดที่ 1 PD 0.219422 เหนือเส้น
a_approach.py	13	ชุดที่ 1 จับได้ 8 จาก 8

กลยุทธ์เตือนภัยหกแบบ ตาราง 10 คือผลของ benchmark_rolling_segmented.py ตรงกับตารางใน README ของคลังทุกช่อง บริษัทที่เกิดเหตุการณ์มี 31 ราย อยู่ในกลุ่ม SET 24 ราย และกลุ่ม mai 7 ราย

Table 10: กลยุทธ์เตือนภัยหกแบบบน Dataset2

กลยุทธ์	เตือน (ราย)	จับได้	Recall	Precision	SET
1. เดือนล่าสุด รวมตลาด	87	13/31	41.9%	14.9%	10/24
2. เดือนล่าสุด แยก SET/mai	86	14/31	45.2%	16.3%	11/24
3. ย้อนหลัง 12 เดือน รวมตลาด	223	23/31	74.2%	10.3%	18/24
4. แยกกลุ่ม + ย้อนหลัง 12 เดือน	243	24/31	77.4%	9.9%	19/24
5. แยกกลุ่ม + ย้อนหลัง 24 เดือน	300	26/31	83.9%	8.7%	21/24
6. เดือนภายใน 12 เดือนก่อนเหตุ	241	22/31	71.0%	9.1%	20/24

การดูย้อนหลังหลายเดือนจับได้มากขึ้นจริง แต่จำนวนบริษัทที่ต้องตรวจเพิ่มจาก 87 เป็น 243 ถึง 300 ราย precision จึงลดจาก 14.9% เหลือ 8.7% ถึง 9.9% ผู้ใช้ต้องเลือกตามกำลังคนที่มี

รูปสามช่องของโปรแกรมหลัก รูปที่ 3 เป็นผลของ ITD ช่อง A คือน้ำหนัก LIME เฉลี่ยจาก 8 seed เส้นคาดคือหนึ่ง SD ช่อง B คือค่า SHAP ช่อง C คือระยะห่างของค่าตัวแปรจากค่ากลางของทั้งตลาด วัดเป็น SD




Figure 3: ผลของ ITD จาก lime33_adapter_panel.py -d 2 --segmented -w 12 --issuer ITD

ข้อควรระวังในการอ่านช่อง B ของโปรแกรมหลัก ค่า SHAP ในช่อง B ของ lime33_adapter_panel.py คำนวณจากคะแนนดิบของ CatBoost ซึ่งอยู่ในหน่วย log-odds ไม่ใช่หน่วยความน่าจะเป็น แม้ชื่อช่องจะเขียนว่า Share of PD ตัวอย่างของ ITD มีค่า PD 0.0113 แต่แท่ง SHAP ขาวถึง ± 1.4 ซึ่งเป็นไปไม่ได้ถ้าเป็นหน่วย PD คอลัมน์ SHAP_Pct_of_PD ในไฟล์ Excel จึงไม่ควรอ่านเป็นร้อยละของ PD ที่สทงและลำดับของแท่งยังใช้ได้ ถ้าต้องการค่า SHAP ที่รวมกลับเป็น PD ได้พอดี ให้ใช้ lime_feature33.py แทน

รูปของ lime_feature33.py รูปที่ 4 เป็นผลของ TPOLY ช่อง B อยู่ในหน่วยความน่าจะเป็น ค่าฐาน 0.016504 รวมกับผลรวม SHAP -0.012140 ได้ PD 0.004364 พอดี ตัวแปรที่มีคำว่า unstable กำกับคือตัวที่ค่า LIME เปลี่ยนเครื่องหมายเมื่อเปลี่ยน seed ไม่ควรนำไปตีความ

[Dataset 2 (941 firms)] TPOLY month 2026-08 PD = 0.004364 review threshold = 0.127681 agree = 8/10
red = pushes PD up blue = pulls PD down




Figure 4: ผลของ TPOLY จาก lime_feature33.py --issuer TPOLY

lead time ของห้าโมเดล (ขั้นที่ 1) ตาราง 11 ได้ตัวเลขตรงกับรอบที่รันเมื่อ 4 กันยายน 2026 ทุกค่า การเตือนนับเป็นการจับได้

เมื่อโมเดลเตือนภายใน 1 ถึง 3 เดือนก่อนเดือนเหตุการณ์ ค่ามัธยฐาน 92 วันจึงเป็นค่าสูงสุดที่เป็นไปได้ของนิยามนี้

Table 11: ผลของ dataset2_leadtime_standalone.py ห้าโมเดล ที่กำลังคน 5%

โมเดล	AUC	Average precision	จับได้	lead (วัน)	เตือนต่อเนื่อง (วัน)
XGBoost	0.9399	0.0150	19/31	92	381.5
CatBoost	0.9037	0.0146	20/31	92	549.0
RandomForest	0.8846	0.0150	13/31	92	397.0
Logistic	0.8241	0.0030	9/31	92	609.0
LightGBM	0.6599	0.0086	14/31	92	486.5

LIME ของห้าโมเดล (ขั้นที่ 2) ตาราง 12 และรูปที่ 5 คือผลของ dataset2_multimodel_lime.py ตัวเลขตรงกับรอบ 4 กันยายน 2026 ทุกค่า คอลัมน์สุดท้ายยืนยันว่าโมเดลที่สร้างใหม่ให้ค่า PD ต่างจากขั้นที่ 1 ไม่เกิน 3.4×10^{-16} คือเป็นโมเดลเดียวกัน

Table 12: ผลของ dataset2_multimodel_lime.py (5 seed ละ 750 จุด)

โมเดล	เหตุการณ์ที่อธิบาย	fidelity (R^2)	ความนิ่งของเครื่องหมาย	ผลต่างของ PD
XGBoost	19/31	0.019	1.0	1.1×10^{-16}
CatBoost	20/31	0.000	0.8	1.1×10^{-16}
RandomForest	13/31	0.013	1.0	3.3×10^{-16}
Logistic	9/31	0.555	1.0	1.1×10^{-16}
LightGBM	14/31	0.070	1.0	1.1×10^{-16}




Figure 5: สรุป LIME ของห้าโมเดล ณ เดือนที่เตือนจริง

อ่านค่า fidelity อย่างไร fidelity คือ R^2 ของเส้นตรงที่ LIME พิจารณาค่านั้น เทียบกับค่าที่โมเดลจริงให้ ค่ามัธยฐานของโมเดลกลุ่มต้นไม้ต่ำมาก อยู่ระหว่าง 0.000 ถึง 0.070 มีเพียง Logistic ที่ได้ 0.555 เพราะโมเดลเองเป็นเส้นตรงอยู่แล้ว แปลว่าสำหรับโมเดลกลุ่มต้นไม้ เส้นตรงของ LIME อธิบายพฤติกรรมเฉพาะที่ของโมเดลได้น้อย น้ำหนัก LIME จึงบอกทิศทางคร่าว ๆ ได้ แต่ไม่ควรอ่านขนาดของน้ำหนักเป็นตัวเลขที่แม่นยำ ในกรณีนี้ควรดูค่า SHAP ประกอบ

วิธี A, B, C บน Dataset2 ตาราง 13 คือผลของ evaluate_methods_abc.py ส่วนของชุดที่ 2 วิธี A คือ PD เหนือเส้น วิธี B คือบริษัทที่ขับตัวแปรเดียวไม่เกิน 1 SD ก็ข้ามเส้น วิธี C คือกำไรสะสมและเงินสดอยู่ใน decile ต่ำสุดทั้งคู่

Table 13: วิธี A, B, C บน Dataset2 ที่กำลังคน 5%

วิธี	เตือน (ราย)	จับได้	Recall	Precision
A ระดับ PD	48	8/31	25.8%	16.7%
B ความแปรปรวน	21	3/31	9.7%	14.3%
C งบแท้ที่ถูกรับ	39	5/31	16.1%	12.8%
A + C	87	13/31	41.9%	14.9%
A + B + C	106	15/31	48.4%	14.2%

บนชุดที่ 1 วิธีเดียวกันจับได้ครบ 8 จาก 8 ราย แต่เกณฑ์ทุกชั้นเลือกจากเหตุการณ์ 8 รายชุดเดียวกับที่ใช้วัดผล ตัวเลขนั้นจึงเข้าข้างตัวเอง บน Dataset2 ซึ่งมีเหตุการณ์ใหม่ 31 ราย วิธีเดียวกันจับได้ 15 ราย เป็นตัวเลขที่สะท้อนความสามารถจริงมากกว่า

5. คลังที่สอง leadning_time: วัด lead time

5.1 หน้าทีของคลัง

คลังนี้ตอบว่าระบบเตือนก่อนเหตุการณ์จริงได้กี่เดือน และจับบริษัทที่เกิดเหตุการณ์ได้กี่ราย มีสองโปรแกรมที่นิยาม lead time ต่างกัน จึงต้องอ่านผลแยกกัน

- `dynamic_lead_time.py` ใช้หน้าต่าง $T-12$ ถึง $T+3$ รอบเตือนเหตุการณ์ T และรายงานสามแบบ คือ broad ($T-12$ ถึง $T+3$), early-only ($T-12$ ถึง $T-1$) และ strict ($T-3$ ถึง $T-1$) lead time คือเตือนเหตุการณ์สลับเดือนที่เดือนครั้งแรก มีทั้งแบบแบ่ง fold ตามบริษัท และแบบฝึกด้วยอดีตแล้วทดสอบปีถัดไป (time-forward)
- `dataset2_leadtime_standalone.py` นับเป็นการจับได้เฉพาะเมื่อเตือนภายใน 1 ถึง 3 เดือนปฏิทินก่อนเหตุการณ์ lead time จึงไม่เกิน 92 วัน และวัดความยาวของการเตือนต่อเนื่องแยกไว้รันได้เก้าโมเดลด้วยการแบ่ง fold เดียวกัน

5.2 โครงสร้างโปรแกรม

Table 14: ไฟล์ในคลัง leadning_time

ไฟล์	หน้าที่
<code>dynamic_lead_time.py</code>	lead time แบบหน้าต่าง $T-12$ ถึง $T+3$ ทั้งแบบแบ่งตามบริษัทและแบบ time-forward
<code>dataset2_leadtime_standalone.py</code>	lead time 1 ถึง 3 เดือนของเก้าโมเดล (ไฟล์เดียวกับใน iBond_LIME)
<code>lime_credit.db.zip</code>	Dataset2 แบบบีบอัด คลายเองในการรันครั้งแรก
<code>run_dynamic_lead_time.bat</code>	ดับเบิลคลิกเพื่อรัน <code>dynamic_lead_time.py</code> บน Windows
<code>requirements*.txt</code>	รายการแพ็คเกจ สามระดับ พื้นฐาน, CatBoost และครบทั้งคลัง
<code>tests/test_core.py</code>	ทดสอบฟังก์ชันคำนวณ lead time
<code>results/</code>	ผลอ้างอิง Excel, SQLite และ CSV
<code>docs/</code>	คู่มือ LaTeX ภาษาไทยเดิมของโปรแกรมแรก และคู่มือฉบับนี้

5.3 วิธีรัน dynamic_lead_time.py

```
python dynamic_lead_time.py
python dynamic_lead_time.py --model catboost
python dynamic_lead_time.py --model numpy
python dynamic_lead_time.py --skip-time-forward
python dynamic_lead_time.py --db ../iBond_LIME/lime_credit.db
python -m unittest discover -s tests -v
```

Table 15: ตัวเลือกหลักของ dynamic_lead_time.py

ตัวเลือก	ค่าเริ่มต้น	ความหมาย
--model	auto	auto ใช้ CatBoost ถ้าติดตั้งไว้ ถ้าไม่มีใช้ logistic ที่เขียนด้วย numpy
--feature-set	report30	report30 คือตัวแปร 30 ตัวของรายงาน correct33 คือ 33 คอลัมน์
--workload	0.05	กำลังคนที่ใช้ตั้งเส้นเดือนกุมภาพันธ์
--window-before,	12, 3	ขอบของหน้าต่างรอบเดือนเหตุการณ์
--window-after		
--skip-time-forward	-	ข้ามการทดสอบแบบ time-forward เพื่อลดเวลา
--db, --table	ค้นหาเอง	ระบุฐานข้อมูลและตารางเอง
--no-excel,	-	ไม่เขียนผลแบบนั้น
--no-sqlite, --no-csv		

โปรแกรมค้นหาฐานข้อมูลเองตามลำดับ คือ path ที่ระบุด้วย --db โฟลเดอร์ที่รันอยู่ โฟลเดอร์ของโปรแกรม โฟลเดอร์แม่ และโฟลเดอร์ย่อย data/ ชื่อที่ค้นคือ cmdf_credit.db, lime_credit.db และ bond_financials.db ถ้าไม่พบเลย จะคลาย lime_credit.db.zip ที่แนบมาผลเขียนลง results/dynamic_lead_time_results.xlsx, results/dynamic_lead_time_results.db และ results/csv/

5.4 วิธีรัน dataset2_leadtime_standalone.py

```
python dataset2_leadtime_standalone.py --version
python dataset2_leadtime_standalone.py self-test
python dataset2_leadtime_standalone.py inspect
python dataset2_leadtime_standalone.py run
python dataset2_leadtime_standalone.py run --models xgboost catboost --workload 0.10
python dataset2_leadtime_standalone.py build-db
```

Table 16: คำสั่งย่อยของ dataset2_leadtime_standalone.py

คำสั่งย่อย	ทำอะไร
self-test	ตรวจสอบ lead time, precision-recall ตาม workload และ probit ด้วยข้อมูลสมมติ ไม่ต้องใช้ฐานข้อมูล
inspect	นับแถว บริษัท เดือน เหตุการณ์ และตรวจแถวซ้ำของตาราง Dataset2
run	ฝึก โมเดลด้วยการแบ่ง fold ตามบริษัท 5 fold แล้ววัด lead time ค่าเริ่มต้นรันครบเก่าโมเดล ระบุบางตัวด้วย --models ชื่อที่ใช้ได้คือ xgboost, catboost, lightgbm, random_forest, logistic, probit, hist_gradient_boosting, gradient_boosting, extra_trees
build-db	คัดตาราง Dataset2 และ ตาราง iBond ดิบ ที่มีอยู่ ไปเป็นฐานข้อมูลชุดใหม่ใน standalone_dataset2/ ฐานข้อมูลค้นทางไม่ถูกแก้
update-ibond	สร้างฐานข้อมูลชุดใหม่ที่ปรับเหตุการณ์ผัดกันจาก iBond ต้องระบุ --base-db และเลือกหนึ่งทาง คือ --from-db อ่าน ตาราง iBond ที่ดาวน์โหลดไว้แล้ว หรือ --download ซึ่ง ต้องมี download_bond.py ของ ibond_EWS และรหัสผ่าน iBond ของผู้ใช้งาน

ผลของ run อยู่ในโฟลเดอร์ standalone_leadtime_runs/standalone_<date>_<time>_<id>/ มีตารางสรุปโมเดล lead time ของทุกเหตุการณ์ precision-recall ที่กำลังคน 1% ถึง 10% ค่า PD แบบ out-of-fold ทุกแถว ฐานข้อมูล SQLite และรูปสามรูป

5.5 ผลการรันบน Dataset2

dynamic_lead_time.py ให้ผลต่างกันตาม backend ผลที่แนบในคลังเดิมรันในเครื่องที่ไม่มี CatBoost และไม่มี scikit-learn จึงใช้ logistic แบบ numpy กับ การแบ่ง fold ที่เขียนเอง รอบนี้รันครบทั้งสามแบบบนเครื่องเดียวกัน ตาราง 17 แสดงว่าผลขึ้นกับแพ็คเกจที่ติดตั้งอย่างมาก ผู้ใช้ต้องดูบรรทัด Model backend ที่โปรแกรมพิมพ์ทุกครั้งก่อนอ่านตัวเลข

Table 17: ผลของ dynamic_lead_time.py บน Dataset2 แยกตาม backend

รายการ	CatBoost	numpy + sklearn fold	numpy + fold เขียนเอง
แบ่งตามบริษัท broad	24/31 = 77.4%	14/31 = 45.2%	13/31 = 41.9%
แบ่งตามบริษัท early-only	22/31 = 71.0%	11/31 = 35.5%	10/31 = 32.3%
แบ่งตามบริษัท strict 1-3 เดือน	21/31 = 67.7%	11/31 = 35.5%	10/31 = 32.3%
time-forward broad	14/26 = 53.8%	8/26 = 30.8%	8/26 = 30.8%
time-forward early-only	11/26 = 42.3%	6/26 = 23.1%	6/26 = 23.1%
time-forward strict 1-3 เดือน	9/26 = 34.6%	6/26 = 23.1%	6/26 = 23.1%
คิวเดือน 12 เดือนล่าสุด (ราย)	256	151	—

คอลัมน์สุดท้ายคัดจากผลเดิมที่แนบในคลังก่อนรอบนี้ time-forward ประเมินได้ 26 ราย เพราะอีก 5 รายเกิดเหตุการณ์ในปี 2020-2021 ก่อนหน้านั้นยังไม่มีบริษัทที่เกิดเหตุการณ์ให้โมเดลเรียน ผลที่แนบในคลังรอบนี้เปลี่ยนเป็นผลของ CatBoost เพราะเป็นสิ่งที่ผู้ใช้จะได้เมื่อติดตั้งตาม requirements-catboost.txt

ผลแบบ early-only ของ CatBoost ได้ 22/31 เท่ากับตัวเลข 71.0% ที่รายงาน LIME เคยอ้าง แต่โปรแกรมเทียบตัวเลขนั้นกับแบบ broad ซึ่งได้ 24/31 สถานะที่พิมพ์ออกมาจึงเป็น NO_MATCH ผลแบบแบ่งตามบริษัทยังมีความเสี่ยงที่โมเดลได้เห็นข้อมูลปีหลังตอนทำนายปีก่อน ผลที่ใกล้เคียงการใช้งานจริงกว่าคือแบบ time-forward

แก้โมเดลของ `dataset2_leadtime_standalone.py` ตาราง 18 คือผลของ `python dataset2_leadtime_standalone.py run` ซึ่งรันครบแก้โมเดลใน 677 วินาที ในจำนวนนี้ GradientBoosting ใช้ 471 วินาที หัวโมเดลแรกโดยตรงกับตาราง 11 ได้ตัวเลขเท่ากันทุกค่า เพราะใช้การแบ่ง fold ชุดเดียวกัน

Table 18: ผลของ `dataset2_leadtime_standalone.py run` แก้โมเดล ที่กำลังคน 5%

โมเดล	AUC	Average precision	จับได้	เตือนต่อเนื่อง (วัน)	วินาที
XGBoost	0.9399	0.0150	19/31	381.5	7
CatBoost	0.9037	0.0146	20/31	549.0	26
LightGBM	0.6599	0.0086	14/31	486.5	9
RandomForest	0.8846	0.0150	13/31	397.0	52
Logistic	0.8241	0.0030	9/31	609.0	6
Probit	0.8350	0.0033	12/31	306.0	16
HistGradientBoosting	0.8777	0.0259	18/31	397.0	8
GradientBoosting	0.9331	0.0154	20/31	411.0	471
ExtraTrees	0.8875	0.0122	20/31	670.0	46

อ่านตารางนี้อย่างไร AUC สูงสุดคือ XGBoost 0.9399 average precision สูงสุดคือ HistGradientBoosting 0.0259 และจับได้มากที่สุด 20 จาก 31 ราย มีสามโมเดล คือ CatBoost, GradientBoosting และ ExtraTrees ค่า average precision ต่ำเพราะเดือนที่เกิดเหตุการณ์มีเพียงร้อยละ 0.066 ของข้อมูล ค่าที่ได้จากการเดาสุ่มจึงเท่ากับ 0.00066 XGBoost ได้ 0.0150 สูงกว่าการเดาสุ่มราว 23 เท่า ไฟล์ผลยังมีคอลัมน์ `pr_auc_trapezoid_oof` ซึ่งคำนวณด้วยวิธีสี่เหลี่ยมคางหมูและเชื่อไม่ได้เมื่อเส้น precision-recall ไม่เรียบ เช่น LightGBM ได้ 0.0954 ทั้งที่ average precision เพียง 0.0086 ให้อ่านคอลัมน์ `average_precision_oof` แทน

รูปที่ 6 แสดงผลรายบริษัทของทุกโมเดล ช่องสีเขียวคือเดือนภายใน 1 ถึง 3 เดือนก่อนเหตุการณ์ พร้อมจำนวนวัน ช่องสีแดงคือไม่มีการเตือนในช่วงนั้น ช่องสีเทาคือไม่มีข้อมูลก่อนเหตุการณ์ ACAP, EA, JTS และ TPCB ไม่มีโมเดลใดจับได้ ส่วน WSOL ไม่มีข้อมูลก่อนเดือนเหตุการณ์จึงประเมินไม่ได้

Standalone lead-time audit by first DP/RS event									
	XGBoost	CatBoost	LightGBM	Random Forest	Logistic	Probit	HistGB	GradientBoosting	ExtraTrees
CGD 2020-06	miss	miss	miss	miss	miss	31 d	61 d	miss	miss
ACAP 2020-07	miss	miss	miss	miss	miss	miss	miss	miss	miss
THAI 2020-07	miss	miss	miss	miss	miss	61 d	miss	miss	miss
JCK 2020-09	miss	miss	miss	miss	92 d	92 d	92 d	miss	miss
CHO 2021-02	92 d	miss	miss	miss	miss	miss	92 d	miss	miss
ALL 2022-09	miss	miss	miss	miss	miss	miss	92 d	92 d	miss
ITD 2024-01	miss	92 d	miss	miss	miss	miss	miss	miss	miss
PROEN 2024-03	miss	miss	miss	miss	miss	miss	miss	miss	29 d
ECF 2024-05	90 d	90 d	90 d	90 d	90 d	90 d	90 d	90 d	90 d
APCS 2024-06	miss	31 d	92 d	miss	miss	miss	miss	miss	92 d
EA 2024-08	miss	miss	miss	miss	miss	miss	miss	miss	miss
EP 2024-09	31 d	31 d	92 d	31 d	92 d	92 d	31 d	31 d	92 d
NWR 2024-09	92 d	92 d	92 d	92 d	miss	miss	92 d	92 d	92 d
STARK 2024-09	92 d	miss	miss	miss	miss	miss	miss	92 d	miss
A 2024-10	92 d	92 d	92 d	92 d	92 d	92 d	92 d	92 d	92 d
WSOL 2024-11	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A	N/A
RICHY 2025-01	92 d	92 d	92 d	miss	92 d	92 d	92 d	92 d	92 d
CV 2025-02	92 d	92 d	92 d	92 d	miss	miss	92 d	92 d	92 d
NRF 2025-02	92 d	92 d	31 d	92 d	miss	miss	92 d	92 d	92 d
PRIME 2025-02	92 d	92 d	miss	miss	92 d	92 d	92 d	92 d	92 d
TPOLY 2025-03	miss	90 d	miss	miss	miss	90 d	miss	90 d	90 d
JTS 2025-04	miss	miss	miss	miss	miss	miss	miss	miss	miss
PF 2025-04	90 d	90 d	90 d	90 d	miss	miss	90 d	90 d	90 d
B 2025-05	89 d	89 d	miss	miss	miss	miss	miss	89 d	89 d
GRAND 2025-06	92 d	92 d	92 d	92 d	miss	miss	miss	92 d	92 d
SQ 2025-06	92 d	92 d	92 d	92 d	miss	miss	92 d	92 d	92 d
CMC 2025-07	91 d	91 d	91 d	91 d	91 d	91 d	91 d	91 d	91 d
MJD 2025-10	92 d	92 d	miss	92 d	92 d	92 d	92 d	92 d	92 d
TTCL 2025-10	92 d	92 d	92 d	92 d	miss	miss	92 d	92 d	92 d
AQUA 2025-11	92 d	92 d	92 d	92 d	92 d	92 d	92 d	92 d	92 d
POWER 2025-11	92 d	92 d	miss	miss	miss	miss	miss	92 d	92 d
TPCH 2025-11	miss	miss	miss	miss	miss	miss	miss	miss	miss

Figure 6: ผลรายบริษัทของเก้าโมเดล จาก standalone_lead_matrix.jpg

รูปที่ 7 แสดง precision และ recall เมื่อเพิ่มกำลังคนจาก 1% ถึง 10% ของบริษัท-เดือน เมื่อตรวจมากขึ้น recall เพิ่มขึ้นแต่ precision ลดลง โมเดลกลุ่มต้นไม้ทุกตัวยกเว้น LightGBM อยู่เหนือ Logistic และ Probit ทุกระดับกำลังคน ส่วน LightGBM ใกล้เคียง Probit เมื่อกำลังคนตั้งแต่ 6% ขึ้นไป




Figure 7: precision และ recall ตามกำลังคน 1% ถึง 10% จาก precision_recall_curve_1_10pct.jpg

ผลอ้างอิงของรอบนี้แนบไว้ในคลังที่ results/standalone_reference/ ได้แก้ตารางสรุปโมเดล lead time ของทุกเหตุการณ์ precision-recall ตามกำลังคน คะแนนเดือนล่าสุด และรูปสามรูป ไม่ได้แนบค่า PD ทุกแถวและฐานข้อมูลผลเพราะมีขนาดรวมราว 35 MB รันใหม่ได้ด้วยคำสั่งเดียว

6. คลังที่สาม ibond_EWS: ระบบเตือนภัยและหน้าจอโปรแกรม

6.1 หน้าแรกของคลัง

คลังนี้เป็นระบบเตือนภัยเต็มรูปแบบ ตอบสนองคำถามหลักรายบริษัท คือตอนนี้อยู่ห่างจากเส้นเตือนภัยเท่าไร และตัวแปรใดต้องขยับไปเท่าไรจึงจะข้ามเส้น มีหน้าจอโปรแกรมที่เขียนด้วย Flet โปรแกรมคำนวณ PD หลายแบบ การ shock ตัวแปร การดึงข้อมูลจาก iBond และการแจ้งเตือนทางอีเมล รอบนี้เพิ่มไฟล์เคอร์ dataset2/ ซึ่งเป็นระบบเดียวกันที่ทำงานบน Dataset2

6.2 โครงสร้างโปรแกรม

Table 19: โฟลเดอร์ในคลัง ibond_EWS

โฟลเดอร์	ไฟล์	เนื้อหา
ราก	2	run.py ตัวเรียกโปรแกรม และ thaibma_paths.py ตัวหาฐานข้อมูล
app/	7	หน้าจอโปรแกรม app.py การเฟิร์มแวร์ อีเมล และ pd11_panel.py
app/legacy/	7	หน้าจอรุ่นเก่า เก็บไว้อ้างอิง
ews/	16	แกนของระบบ PD เส้นเดือนกับ โมเมนตัม การ shock ราชบริษัท และ LIME
models/	17	โมเดลกลุ่มคันไม้ เส้นอัตราผลตอบแทน และ Koopman
analysis/	15	การ shock ที่ละคู่และที่ละสาม PCA และความสำคัญของตัวแปร
reanalysis/	3	การประเมินรอบใหม่ตามข้อเท็จจริงของผู้ประเมินบทความ
data/	22	ดึงข้อมูล iBond สร้างแพคเกจตัวแปร และดูแลฐานข้อมูล
reporting/	9	สร้างตาราง รูป และไฟล์ LaTeX
bench/	4	วัดเวลาและรันชุดใหญ่
integrations/	3	เชื่อมต่อ OpenClaw
tests/	11	สคริปต์ตรวจสอบ
dataset/	1	ข้อมูลสี่ตาราง (csv.gz) และ build_db.py
dataset2/	6	ระบบบน Dataset2: หน้าจอ ตัวอ่านข้อมูล lead time แก้วโมเดล และกราฟ PD
docs/	-	คู่มือฉบับนี้

Table 20: ไฟล์ในโฟลเดอร์ dataset2/

ไฟล์	หน้าที่
app_dataset2.py	หน้าจอโปรแกรมรุ่น Dataset2 มีแก้วแผง เช่น Survival Dashboard, XGBoost + SHAP, Firm Shock, Lead Time และ Model Zoo
data_layer.py	อ่าน Dataset2 บัญชีเหตุการณ์ โมเดลแก้วแบบ PD แบบ out-of-fold lead time และ โมเมนตัม
leadtime_allmethods.py	lead time 1 ถึง 3 เดือนของแก้วโมเดล (โปรแกรมเดียวกับ dataset2_leadtime_standalone.py)
pd_curves.py	PD 3 เดือนของ Approach 1 (logit) กับ Approach 2 (gradient boosting) และกราฟราชบริษัท
run_all_methods.py	รันทุกโมเดลแล้วเขียนตารางลง dataset2/out/
make_pr_figure.py	รูป precision-recall ของทุกโมเดลในภาพเดียว

6.3 การติดตั้งและสร้างฐานข้อมูล

```
cd ibond_EWS
python -m pip install -r requirements.txt
```

```
python dataset/build_db.py
python thaibma_paths.py
```

`build_db.py` สร้าง `cmdf_credit.db` ที่รากของคลังจากไฟล์ CSV ที่ตาราง ใช้เวลาราว 8 วินาที คำสั่งสุดท้ายพิมพ์ตำแหน่งที่โปรแกรมหาฐานข้อมูลเจอ `thaibma_paths.py` ค้นหาตามลำดับ คือตัวแปรสภาพแวดล้อม `THAIBMA_DATA` ถ้ามีรากของคลัง แล้วไล่ขึ้นไปโฟลเดอร์แม่ทีละชั้นไม่เกินแปดชั้น ผู้ใช้จึงไม่ต้องตั้ง path เอง

รหัสผ่าน `iBond` และอีเมลอ่านจากตัวแปรสภาพแวดล้อมเท่านั้น ได้แก่ `THAIBMA_USER`, `THAIBMA_PASS`, `SMTP_USER` และ `SMTP_PASS` ไม่มีการเก็บไว้ในโค้ด เจ้าของบัญชีต้องตั้งค่าเองบนเครื่องของตน ถ้าไม่ได้ตั้ง โปรแกรมส่วนที่ไม่ต้องดึงข้อมูลใหม่หรือส่งอีเมลยังทำงานได้ตามปกติ

6.4 วิธีรัน

ก. ตัวเรียกโปรแกรม `run.py` โปรแกรมในคลังนี้ import กันด้วยชื่อสั้น `run.py` จึงใส่ทุกโฟลเดอร์ลง `sys.path` ก่อน แล้วเรียกโปรแกรมตามชื่อ อาร์กิวเมนต์ที่ตามหลังส่งต่อให้โปรแกรมนั้นตามปกติ

```
python run.py --list
python run.py app
python run.py hyperbolic_boundary_panel --no-figure
python run.py a_approach --explain SQ
python run.py pd11_panel performance
```

ข. หน้าจอโปรแกรมหลัก `python run.py app` เปิดหน้าจอหลัก มีเมนู 34 ปุ่ม เช่น Approach 1: Survival Dashboard, Approach 2: XGBoost + SHAP, Firm Shock & PD Threshold, Momentum & Hyperbolic Boundary, วิธี A: Three-layer Review Queue, Explainable AI: LIME + SHAP, `iBond` Connection & API, Monitoring & Email Alerts, แสดง graph probability default และ Run PD: 11 methods เมนูวิธี A กับ Explainable AI เรียก `a_approach.py` และ `lime_panel.py` ที่เพิ่มในรอบนี้ สองเมนูสุดท้ายเรียก `pd11_panel.py` ซึ่งอ่านผลจากโฟลเดอร์ `dataset2/` เมนูที่อ่านตารางปฏิบัติการ เช่นประวัติการส่งอีเมล จะว่างเพราะตารางเหล่านั้นไม่ได้แนบในคลัง

ค. ระบบ Dataset2

```
python dataset2/data_layer.py --selftest
python dataset2/app_dataset2.py
python dataset2/app_dataset2.py --selftest
python dataset2/app_dataset2.py --uitest
python dataset2/app_dataset2.py --summary
python dataset2/leadtime_allmethods.py run
python dataset2/pd_curves.py build
python dataset2/pd_curves.py events
python dataset2/pd_curves.py issuer "THAI AIRWAYS"
python run.py pd11_panel performance
python run.py pd11_panel issuer "THAI AIRWAYS"
```

Table 21: คำสั่งของระบบ Dataset2 ใน ibond_EWS

คำสั่ง	ทำอะไร
app_dataset2.py	เปิดหน้าจอ Dataset2 เลือกโมเดลและกำลังคนได้ที่แถบด้านซ้าย
app_dataset2.py --selftest	ฝึก XGBoost วาดทุกรูปโดยไม่เปิดหน้าจอ แล้วพิมพ์ผล
app_dataset2.py --uitest	สร้างทุกแผงโดยไม่เปิดหน้าจอ เพื่อตรวจสอบว่าไม่มีส่วนใดพัง
app_dataset2.py --summary	พิมพ์ผลของทุกโมเดลว่าจับได้กี่รายโดยไม่เปิดหน้าจอ
leadtime_allmethods.py run	lead time แก้ว โมเดล ผลลง dataset2/standalone_leadtime_runs/
pd_curves.py build	คำนวณ PD ของ Approach 1 และ 2 ลง dataset2/pd_curves.db
pd_curves.py events	กราฟ PD ของบริษัทที่เกิดเหตุการณ์ 32 ราย
pd_curves.py issuer <name>	กราฟ PD ของบริษัทใดก็ได้ ระบุรหัสหรือชื่อบางส่วน
pd11_panel.py performance	ตารางผลของแก้วโมเดลกับสอง Approach อ่านจากสองคำสั่งก่อนหน้า

pd11_panel.py อ่านผลที่ leadtime_allmethods.py run และ pd_curves.py build เขียนไว้ จึงต้องรันสองคำสั่งนั้นก่อน ถ้าสั่ง python run.py pd11_panel run โปรแกรมจะรันทั้งสองให้เองและพิมพ์ความคืบหน้า

ง. โปรแกรมบนชุดข้อมูลเดิม a_approach.py, lime_panel.py, firm_shock_panel.py และ hyperbolic_boundary_panel.py อ่านตาราง ibond_33features_panel (293 ผู้ออก) โดยตรง จึงใช้กับ Dataset2 ไม่ได้ ระบบที่ใช้ Dataset2 คือไฟล์เดอร์ dataset2/ ทั้งหมด

6.5 ผลการรันบน Dataset2

คำสั่งที่รันและเวลาที่ใช้ ตาราง 22 คือคำสั่งที่รันจริงบนสำเนาใหม่ของคลัง หลังสร้างฐานข้อมูลจาก CSV แล้ว ทุกคำสั่งจบโดยไม่มีข้อผิดพลาด

Table 22: คำสั่งที่รันในคลัง ibond_EWS และผลโดยย่อ

คำสั่ง	วินาที	ผลโดยย่อ
dataset/build_db.py	8	ใส่ตาราง ได้ cmdf_credit.db 109.5 MB
run.py --list	0	พบ 122 โปรแกรม
dataset2/data_layer.py --selftest	10	187,007 แถว 941 บริษัท ตัวแปร 30 ตัว แก้วโมเดล ผ่าน
dataset2/app_dataset2.py --selftest	19	XGBoost AUC 0.9379 จับได้ 19/31 วาดครบ 8 รูป
dataset2/app_dataset2.py --uitest	805	รันแก้วโมเดล และสร้างครบ 10 แผง ผ่าน
dataset2/leadtime_allmethods.py self-test	2	ผ่าน
dataset2/leadtime_allmethods.py inspect	3	ตรงกับตาราง 2 ทุกค่า
dataset2/pd_curves.py build	19	ตาราง 24
dataset2/pd_curves.py self-test	4	ผ่าน วาดกราฟของ CGD ได้
run.py pd11_panel performance	1	ตาราง 25
run.py a_approach --no-figure	12	ชุดที่ 1 เส้น PD 0.066002 จับได้ 8/8
run.py hyperbolic_boundary_panel --no-figure	10	ชุดที่ 1 เดือนเหตุการณ์ 32 จาก 32 อยู่ฝั่งเดือน
run.py lime_panel --help	2	แสดงตัวเลือกได้
python -c "import run, app"	-	import หน้าจอหลักได้ครบทุกโมดูล

ผลของหน้าจอ Dataset2 app_dataset2.py --uitest รันทุก โมเดลก่อนสร้างแผงแรก ซึ่งสรุปว่าแต่ละ โมเดลจับบริษัทที่เกิดเหตุการณ์ได้กี่ราย ตาราง 23 คือผลที่พิมพ์ออกมา โมเดลบางตัวตั้งค่าต่างจาก leadtime_allmethods.py จึงได้ตัวเลขต่างจากตาราง 18 เช่น LightGBM จับได้ 10 ราย แทน 14 ราย และ Probit 16 ราย แทน 12 ราย ส่วน CatBoost, GradientBoosting, ExtraTrees และ Logistic ได้ตัวเลขเท่ากัน ให้เทียบ โมเดลภายในโปรแกรมเดียวกันเท่านั้น

Table 23: ผลของแก้วโมเดลในหน้าจอ Dataset2 (app_dataset2.py) ที่กำลังคน 5%

โมเดล	AUC	Average precision	จับได้
XGBoost	0.9379	0.0147	19/31
LightGBM	0.6058	0.0042	10/31
CatBoost	0.9037	0.0146	20/31
HistGradientBoosting	0.9393	0.0192	18/31
GradientBoosting	0.9331	0.0154	20/31
RandomForest	0.8302	0.0122	14/31
ExtraTrees	0.8875	0.0122	20/31
Logistic	0.8241	0.0030	9/31
Probit	0.6776	0.0013	16/31

PD ของ Approach 1 และ Approach 2 pd_curves.py build จำนวน PD 3 เดือนของสองแนวทางด้วยการแบ่ง fold

เดียวกัน บนชุดความเสี่ยงที่ตัดเดือนหลังเหตุการณ์แรกของแต่ละบริษัทออก 752 แถว เหลือ 186,255 แถว ทั้งสองแนวทางใช้สูตร $\widehat{PD}_{3M} = 1/(1 + e^{-F(x)})$ เหมือนกัน ต่างกันที่ $F(x)$ โดย Approach 1 เป็นเชิงเส้น (pooled logit) และ Approach 2 เป็นผลรวมของต้นไม้ (gradient boosting) ตาราง 24 ได้ตัวเลขตรงกับรอบ 4 กันยายน 2026 ทุกค่า

Table 24: ผลของ pd_curves.py build

แนวทาง	AUC	Average precision	จับได้ 1-3 เดือน	lead (วัน)
Approach 1 (pooled logit)	0.8144	0.0032	12/32	92
Approach 2 (gradient boosting)	0.9522	0.0213	24/32	92

บริษัทที่ทั้งสองแนวทางจับได้มี 11 ราย และไม่มีแนวทางใดจับได้ 7 ราย

ตารางของ 11 วิธีใน **pd11_panel.py** ตาราง 25 คือผลของ python run.py pd11_panel performance ซึ่งอ่านผลของสองคำสั่งก่อนหน้ามารวมกัน คอลัมน์ panel บอกว่าผลมาจากแผงใด แก้ววิธีแรกใช้แผงเต็ม 187,007 แถว สองแนวทางหลังใช้ชุดความเสี่ยง 186,255 แถว ตัวหารของการจับได้จึงเป็น 31 กับ 32 ต่างกัน

Table 25: ผลของ pd11_panel.py performance

วิธี	panel	AUC	Average precision	จับได้
XGBoost	full	0.9399	0.0150	19/31
CatBoost	full	0.9037	0.0146	20/31
LightGBM	full	0.6599	0.0086	14/31
RandomForest	full	0.8846	0.0150	13/31
Logistic	full	0.8241	0.0030	9/31
Probit	full	0.8350	0.0033	12/31
HistGradientBoosting	full	0.8777	0.0259	18/31
GradientBoosting	full	0.9331	0.0154	20/31
ExtraTrees	full	0.8875	0.0122	20/31
Approach 1	risk_set	0.8144	0.0032	12/32
Approach 2	risk_set	0.9522	0.0213	24/32

ชุดข้อมูลเดิมหลังปรับเป็น 30 ตัวแปร บนชุดที่ 1 เส้นเดือนภัยที่กำลังคน 5% เปลี่ยนจาก 0.026881 ในรุ่นที่ใช้ 33 ตัวแปร เป็น 0.066002 จำนวนผู้ออกเหนือเส้นยังเป็น 15 ราย และคิวสามชั้นยังจับผู้ออกที่เคยเกิดเหตุการณ์ได้ครบ 8 จาก 8 ราย

7. สิ่งปรับปรุงในคลังรอบนี้และข้อควรทราบ

7.1 iBond_LIME

- ชุดข้อมูลที่ 1 รันไม่ได้ แก้แล้ว data_adapter.py ตั้งตัวแปรตามของชุดที่ 1 เป็น d_DP_RS ซึ่งไม่มีในตารางนั้น ตัวแปรตามจึงเป็นศูนย์ทั้งหมด และ lime33_adapter_panel.py -d 1 หักด้วย IndexError แก้เป็น y_fwd ซึ่งเป็นคอลัมน์

เหตุการณ์ของตารางนั้น ได้ 32 เดือนจาก 8 ผู้ออก และแก้ไขกลุ่มที่ไม่มีบริษัทเลยใช้เส้นเดือนกับรวมแทน ผลของ Dataset2 ไม่เปลี่ยน

- path ของเครื่องพัฒนาฝังอยู่ในโค้ด แก้แล้ว benchmark_rolling_segmented.py, evaluate_methods_abc.py และ batch_run_20_issuers.py อ้าง d:\tadgan_gaf\... โดยตรง บนเครื่องอื่นจึงรันไม่ได้ และ batch_run_20_issuers.py import โมดูลชื่อที่ไม่มีในคลัง ตอนนี้ทุกโปรแกรมอ้างไฟล์เครื่องของตัวเอง
- เพิ่ม LIME ของห้าโมเดลบน Dataset2 dataset2_leadtime_standalone.py และ dataset2_multimodel_lime.py ซึ่งเป็นที่มาของผล LIME หลายโมเดลในรายงาน ให้หาฐานข้อมูลในคลังได้เอง
- cmdf_tree_classify.py ใช้ lime_credit.db เมื่อไม่มี cmdf_credit.db lime_feature33.py ใช้ชุดที่ 2 เมื่อรันแบบไม่มีหน้าจอ ตรงกับค่าเริ่มต้นของเมนู

7.2 leading_time

- เพิ่ม dataset2_leadtime_standalone.py รุ่น 1.2.1 ซึ่งรันได้เก้าโมเดล
- แนบ lime_credit.db.zip และให้ dynamic_lead_time.py คลายเองเมื่อหาฐานข้อมูลไม่พบ เดิมผู้ใช้ต้องหาฐานข้อมูลมาวางเอง
- เปลี่ยนผลอ้างอิงใน results/ เป็นผลของ CatBoost และเก็บผลเดิมของ numpy ไว้ในตาราง 17 เพื่อเทียบ
- เพิ่ม requirements-standalone.txt

7.3 ibond_EWS

- เพิ่มระบบ Dataset2 แนบตาราง Dataset2 เป็น CSV ให้ build_db.py สร้างกลับได้ครบทุกบิตและเพิ่มไฟล์เครื่อง dataset2/ ที่เมนู PD ของ app.py ต้องใช้ เดิมเมนูนั้นเรียกไฟล์ที่ไม่มีในคลัง
- เพิ่มสองโปรแกรมที่หน้าจอหลักเรียกแต่ไม่มีในคลัง ews/a_approach.py และ ews/lime_panel.py
- จำนวนตัวแปรตรงกับ README models/cmdf_tree_classify.py และ data/load_bond.py เดิมยังใช้ 33 ตัว รวมคอลัมน์ Amihud ที่ซ้ำกันสามคอลัมน์ ปรับเป็น 30 ตัวสำหรับ โมเดลกลุ่มต้นไม้ และ 31 ตัวสำหรับ logistic hazard ตามรุ่นล่าสุดในเครื่องพัฒนา

7.4 ข้อควรทราบ

- ตัวเลข recall ของหลายโปรแกรมในเอกสารนี้ใช้นิยามต่างกัน ทั้งหน้าต่างเวลา กำลังคน และการแบ่งข้อมูล จึงเทียบข้ามตารางโดยตรงไม่ได้ ต้องเทียบภายในตารางเดียวกันเท่านั้น
- การแบ่ง fold ตามบริษัทป้องกันไม่ให้โมเดลจำบริษัทได้ แต่ไม่ได้กันไม่ให้โมเดลเห็นข้อมูลปีหลัง ตัวเลขที่ได้จึงเป็นขอบบน ผลแบบ time-forward ใกล้เคียงการใช้งานจริงกว่า
- LIME อธิบายโมเดลกลุ่มต้นไม้ได้ไม่ดีนัก ค่า fidelity ต่ำ ควรอ่านคู่กับ SHAP
- ช่อง B ของรูปสามช่องใน lime33_adapter_panel.py อยู่ในหน่วย log-odds ไม่ใช่ร้อยละของ PD ตามที่ชื่อช่องเขียน

- หน้าจอโปรแกรมทดสอบด้วยการสร้างทุกแผงโดยไม่เปิดหน้าต่าง ยังไม่ได้ทดสอบด้วยการกดทีละปุ่ม
- ข้อมูลในแผงมาจากสื่อ iBond ของ ThaiBMA ก่อนนำไปเผยแพร่ต่อ โปรดตรวจสอบเงื่อนไขสิทธิการใช้งานของท่านเอง

ภาคผนวก ก. คำสั่งทั้งหมดโดยย่อ

iBond_LIME

```
python lime33_adapter_panel.py -d 2 --segmented -w 12 --issuer ITD
python lime33_adapter_panel.py -d 2 --segmented -w 12 --all-high-risk
python lime_feature33.py -d 2 --issuer PTT
python batch_run_20_issuers.py
python benchmark_rolling_segmented.py
python evaluate_methods_abc.py
python dataset2_leadtime_standalone.py run --models xgboost catboost random_forest logistic lightgbm
python dataset2_multimodel_lime.py run
```

leadning_time

```
python dynamic_lead_time.py
python dataset2_leadtime_standalone.py inspect
python dataset2_leadtime_standalone.py run
python -m unittest discover -s tests -v
```

ibond_EWS

```
python dataset/build_db.py
python run.py app
python dataset2/app_dataset2.py
python dataset2/leadtime_allmethods.py run
python dataset2/pd_curves.py build
python run.py pd11_panel performance
```